



흡연 여부 데이터 분석을 통한 건강 인사이트 도출

10조

김은미 홍승완 박강호



목차

1. 프로젝트 개요
2. 분석 목표
3. 데이터 구조 및 탐색
4. 데이터 시각화
5. 단변량 분석
6. 이변량 분석
7. 결론 및 인사이트
8. 프로젝트 활용방안

1. 프로젝트 개요

- 건강검진 데이터를 활용하여 흡연 여부를 데이터 기반으로 분석
- 흡연자 vs 비흡연자 간 건강 지표 차이 비교
- 통계 분석을 통해 흡연과 관련된 주요 변수 도출



2. 분석 목표

- 흡연은 건강 지표 중 어떤 지표에 영향을 미치는가?
 - 흡연자 **vs** 비흡연자 간 건강 지표 차이 비교
 - 통계 검정을 통해 유의미한 차이 존재 여부 확인
- 흡연이 신체에 어떤 변화를 유발하는가?
 - ※분석 지표
 - 혈액인자의 변화 : 헤모글로빈, 공복혈당
 - 지질 및 대사 지표 : 고밀도지단백(HDL), 중성 지방
 - 장기 기능 지표 : 혈청 크레아티닌, 간 효소율
- 흡연과 가장 관련있는 핵심 변수는 무엇인가?
 - 변수 간 상관관계 분석
 - 시각화를 통한 패턴 탐색

3. 데이터구조 및 탐색

- **BMI와 나이대 컬럼 추가**

- BMI와 나이대 별로 흡연에 따른 결과가 달라질 것이며 자료를 더 세분화 하여 자세한 자료를 얻기 위해서이다.

- **결측치 확인 및 처리**

- 혈압은 중앙값 :

중앙값은 이상치의 영향을 최소화하고 데이터의 분포를 잘 유지 시킬 수 있음.

- 시력은 최빈값 :

최빈값은 실제 시력 분포에 크게 영향을 미치지 않기에 데이터를 보존 시킬 수 있음.

- 나이대별 중성지방은 그룹 평균:


나이대와 중성지방의 관계 그리고 데이터의 통계적 특성과 패턴을 더 잘 유지시킬 수 있음.

- 공복 혈당은 평균 :


데이터의 전반적인 평균 수치를 유지할 수 있음

4. 데이터 시각화


흡연여부에 따른 나이별 콜레스테롤




흡연여부에 따른 나이별 시력




흡연여부에 따른 나이별 혈압




흡연여부에 따른 나이별 저밀도지단백




흡연여부에 따른 나이별 간 효소율






흡연여부에 따른 나이별 요 단백




흡연여부에 따른 나이별 BMI




4. 데이터 시각화




흡연여부에 따른 나이별 혈청 크레아티닌



흡연여부에 따른 나이별 고밀도지단백



흡연여부에 따른 나이별 헤모글로빈



4. 데이터 시각화

- 위 그래프들을 사용한 이유

- 총치와 나이대별, 비만상태는 범주형에 속하므로 전체의 크기와 비율을 쉽게 볼 수 있으며 모양이 간결하고 직관적이어서 보기가 쉽지만 복잡한 관계를 나타낼 때는 부적합합니다.

- 중성 지방과 혈청 크레아티닌은 박스 플롯으로 데이터의 분포를 시각적으로 표현하며 중앙값과 사분위수, 이상치를 그림으로 쉽게 보여줌으로 각 그래프의 오류를 쉽게 확인 할 수 있습니다.

- 헤모글로빈과 고밀도지단백, 간 효소율은 바이올린 플롯으로 박스 플롯과 비슷하게 중앙값과 사분위수를 잘 보여주며 데이터의 밀도를 보여주며 분포도를 쉽게 확인할 수 있습니다.



5. 단변량 분석

□ 기초 통계량 확인

□ info() 함수 사용

□ 변수 전체 파악 및 결측치 확인

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7000 entries, 0 to 6999
Data columns (total 20 columns):
#   Column                Non-Null Count  Dtype
---  -
0   ID                    7000 non-null   object
1   나이                  7000 non-null   int64
2   키(cm)               7000 non-null   int64
3   몸무게(kg)           7000 non-null   int64
4   BMI                  7000 non-null   float64
5   시력                 7000 non-null   float64
6   충치                 7000 non-null   int64
7   공복 혈당            7000 non-null   float64
8   혈압                 7000 non-null   float64
9   중성 지방            7000 non-null   float64
10  혈청 크레아티닌      7000 non-null   float64
11  콜레스테롤           7000 non-null   int64
12  고밀도지단백         7000 non-null   int64
13  저밀도지단백         7000 non-null   int64
14  헤모글로빈           7000 non-null   float64
15  요 단백질            7000 non-null   int64
16  간 효소              7000 non-null   float64
17  label                7000 non-null   int64
18  BMI 구간             7000 non-null   category
19  나이대               7000 non-null   category
dtypes: category(2), float64(8), int64(9), object(1)
memory usage: 998.7+ KB
```

5. 단변량 분석

- describe()로 평균, 중앙값, 표준편차, 최솟값, 최댓값 확인

	ID	나이	키 (cm)	몸무게 (kg)	BMI	시력	총치	공복 혈당	혈압	중성 지방	혈청 크레아티닌	콜레스테롤	고밀도지단백	저밀도지단백	해모글로빈	요 단백질	간 효소율	label	BMI 구간	나이대
count	7000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000.000000	7000	7000
unique	7000	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	6	7
top	TRAIN_6999	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	정상	40대
freq	1	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2728	2806
mean	NaN	43.973571	164.781429	65.932857	24.144423	1.015186	0.227429	99.307289	45.544000	127.021938	0.884900	197.276571	57.355429	115.346857	14.631914	1.083857	1.144696	0.367286	NaN	NaN
std	NaN	12.063793	9.170213	12.978702	3.501945	0.426631	0.419202	20.977056	8.743135	72.492839	0.241523	36.306494	14.506945	41.788153	1.540907	0.392051	0.432735	0.482100	NaN	NaN
min	NaN	20.000000	135.000000	30.000000	14.270000	0.100000	0.000000	57.000000	14.000000	21.000000	0.100000	86.000000	18.000000	1.000000	4.900000	1.000000	0.140000	0.000000	NaN	NaN
25%	NaN	35.000000	160.000000	55.000000	21.600000	0.800000	0.000000	89.000000	40.000000	74.000000	0.800000	173.000000	47.000000	92.000000	13.600000	1.000000	0.840000	0.000000	NaN	NaN
50%	NaN	40.000000	165.000000	65.000000	23.880000	1.000000	0.000000	96.000000	45.000000	108.000000	0.900000	195.000000	55.000000	113.000000	14.800000	1.000000	1.100000	0.000000	NaN	NaN
75%	NaN	50.000000	170.000000	75.000000	26.120000	1.200000	0.000000	103.000000	50.000000	160.000000	1.000000	219.000000	66.000000	136.000000	15.700000	1.000000	1.380000	1.000000	NaN	NaN
max	NaN	85.000000	190.000000	130.000000	42.450000	9.900000	1.000000	386.000000	91.000000	399.000000	10.000000	395.000000	157.000000	1340.000000	20.900000	5.000000	5.670000	1.000000	NaN	NaN

비흡연자 (0) 기초 통계량

	나이	키 (cm)	몸무게 (kg)	BMI	시력	총치	공복 혈당	혈압	중성 지방	혈청 크레아티닌	콜레스테롤	고밀도지단백	저밀도지단백	해모글로빈	요 단백질	간 효소율	label
count	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.00	4429.0
mean	45.58	162.02	62.85	23.81	0.99	0.2	97.54	45.42	113.45	0.85	197.53	59.35	116.39	14.16	1.09	1.21	0.0
std	12.21	9.32	12.52	3.44	0.45	0.4	17.13	8.97	64.11	0.26	35.82	14.70	42.79	1.56	0.40	0.43	0.0
min	20.00	135.00	30.00	14.27	0.10	0.0	57.00	14.00	23.00	0.40	95.00	24.00	12.00	4.90	1.00	0.29	0.0
25%	40.00	155.00	55.00	21.48	0.80	0.0	88.00	40.00	69.00	0.70	174.00	49.00	94.00	13.10	1.00	0.91	0.0
50%	45.00	160.00	60.00	23.44	1.00	0.0	95.00	45.00	97.00	0.80	195.00	58.00	114.00	14.20	1.00	1.16	0.0
75%	55.00	170.00	70.00	25.71	1.20	0.0	102.00	50.00	138.00	1.00	219.00	68.00	136.00	15.30	1.00	1.44	0.0
max	85.00	190.00	130.00	42.45	9.90	1.0	313.00	91.00	397.00	10.00	395.00	157.00	1340.00	19.30	5.00	5.67	0.0

흡연자 (1) 기초 통계량









	나이	키 (cm)	몸무게 (kg)	BMI	시력	총치	공복 혈당	혈압	중성 지방	혈청 크레아티닌	콜레스테롤	고밀도지단백	저밀도지단백	해모글로빈	요 단백질	간 효소율	label
count	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.00	2571.0
mean	41.21	169.53	71.24	24.73	1.06	0.28	102.35	45.76	150.40	0.95	196.84	53.91	113.55	15.44	1.08	1.04	1.0
std	11.28	6.62	12.01	3.53	0.39	0.45	26.04	8.33	79.79	0.19	37.13	13.49	39.95	1.11	0.39	0.41	0.0
min	20.00	145.00	40.00	15.57	0.10	0.00	60.00	17.00	21.00	0.10	86.00	18.00	1.00	8.90	1.00	0.14	1.0
25%	35.00	165.00	65.00	22.49	0.85	0.00	90.00	40.00	90.00	0.80	171.00	45.00	89.00	14.80	1.00	0.76	1.0
50%	40.00	170.00	70.00	24.22	1.05	0.00	97.00	45.00	131.00	0.90	195.00	52.00	111.00	15.50	1.00	0.97	1.0
75%	50.00	175.00	80.00	27.06	1.20	1.00	105.00	50.00	192.50	1.00	219.00	61.00	136.00	16.10	1.00	1.26	1.0
max	80.00	190.00	125.00	40.82	5.95	1.00	386.00	79.00	399.00	5.90	386.00	132.00	910.00	20.90	5.00	5.47	1.0

- 중성 지방 변수가 평균과 중앙값의 차이가 나는 것을 확인
- 이상치 체크 필요

5. 단변량 분석

(1) 수치형 변수에 대한 histogram + boxplot


[나이,키(cm),몸무게(kg),BMI]




5. 단변량 분석

(1) 수치형 변수에 대한 histogram + boxplot


[시력, 공복혈당]




[혈압, 중성지방]



[혈청 크레아틴, 콜레스테롤]







[고밀도지단백, 저밀도지단백]



5. 단변량 분석

(1) 수치형 변수에 대한 histogram + boxplot





[헤모글로빈 , 간 효소율]



- 공복혈당, 중성 지방, 혈청 크레아티닌, 고밀도지단백, 헤모글로빈, 간 효소율

5. 단변량 분석



(2) 범주형 변수에 대한 변수 분포 확인



5. 단변량 분석

(2) 범주형 변수에 대한 변수 분포를 **비율**로 확인





[총치, 요 단백질]



5. 단변량 분석

(3) 나이에 대한 변수를 통제하여 수치형 변수에 대한 **Boxplot**(이상치 확인) 과 **Lineplot**(안정성, 신뢰구간 확인) 확인.


[중성지방, 혈청 크레아티닌]



5. 단변량 분석

(3) 나이에 대한 변수를 통제하여 수치형 변수에 대한 **Boxplot**(이상치 확인) 과 **Lineplot**(안정성, 신뢰구간 확인) 확인.


[고밀도지단백, 공복혈당]



5. 단변량 분석

(3) 나이에 대한 변수를 통제하여 수치형 변수에 대한 **Boxplot**(이상치 확인) 과 **Lineplot**(안정성, 신뢰구간 확인) 확인.


[헤모글로빈, BMI]




5. 단변량 분석

(3) 나이에 대한 변수를 통제하여 수치형 변수에 대한 **Boxplot**(이상치 확인) 과 **Lineplot**(안정성, 신뢰구간 확인) 확인.

[혈당, 콜레스테롤]



[저밀도지단백, 간 효소율]





※ 흡연자 비중이 가장 높은 30~50대 연령층에서 **5개 주요 건강 지표** (중성지방, 혈청 크레아티닌, 고밀도지단백, 공복혈당, 헤모글로빈) 가 비흡연자 대비 유의미하게 악화된 것으로 확인

5. 단변량 분석

(3) 범주형 변수(비율)에 대한 나이대별 확인


[총치, 요 단백질]



5. 단변량 분석

흡연 여부에 따른 주요 건강 지표 변화


중성 지방



흡연자는 중성 지방 수치가 명확히 높음
 중앙값: 131 (흡연) vs 97 (비흡연)
 +34 증가 (≈ 35% 상승)

- 강한 비정규 분포 (오른쪽 꼬리)
- 40~50대에서 격차 최대흡연 → 산소 운반 능력 보상 증가 가능성
- 흡연 → 지질대사 악화 가능성


헤모글로빈



흡연자는 헤모글로빈 수치가 명확히 높음
 평균: 15.44 (흡연) vs 14.16 (비흡연)
 중앙값: 15.5 vs 14.2
 표준편차 ↓ → 높은 값에 집중

- 모든 나이대에서 일관된 상승
- 분포 자체가 완전히 분리됨
- 흡연 → 산소 운반 능력 보상 증가 가능성

고밀도지단백 (HDL)



흡연자는 HDL이 낮음
 평균: 53.91 (흡연) vs 59.35 (비흡연)
 중앙값: 52 vs 58.

- 모든 나이대에서 일관된 감소
- 흡연 → 혈관 보호 기능 저하

- **총치** : 흡연과 상관관계 존재. 인과관계 해석은 불가
- **공복혈당, 혈청 크레아티닌**

6. 이변량 분석


- 숫자형 변수 **vs** 숫자형 변수
 - 상관분석 (Correlation Analysis)
- 범주형 변수 **vs** 범주형 변수
 - 카이제곱 검정 (Chi-squared Test)
- 범주형 변수 **vs** 숫자형 변수
 - t-검정 (t-test)
 - 분산 분석 (ANOVA)
- 숫자형 변수 **vs** 범주형 변수
 - 로지스틱 회귀모형을 통해, 회귀계수의 P-value로 검정



6. 이변량 분석

숫자형 변수 vs 숫자형 변수 : 상관분석 (Correlation Analysis)

변수 간 상관관계 Heatmap



6. 이변량 분석

범주형 변수 vs 범주형 변수 : 카이제곱 검정 (Chi-squared Test)

- ❖ **p-value < 0.05 : 통계적으로 유의미한 차이 있음**
- ❖ **p-value >= 0.05 : 통계적으로 유의미한 차이 없음**

지표	p-value	결과
총치	2.2327e-16	유의미한 관계가 있음 (귀무가설 기각)
BMI 상태	1.4239e-23	유의미한 관계가 있음 (귀무가설 기각)
나이대	1.2759e-48	유의미한 관계가 있음 (귀무가설 기각)

6. 이변량 분석

범주형 변수 vs 숫자형 변수 : t-검정 (t-test)

- 지표 그룹 : 흡연자/비흡연자

- ❖ **t-value < 0.05 : 통계적으로 유의미한 차이 있음**
- ❖ t-value >= 0.05 : 통계적으로 유의미한 차이 없음

지표	t-value	결과
중성 지방	1.6969e-85	비흡연자(113.45) vs 흡연자(150.40) 유의미한 차이 있음 (흡연자 그룹이 높음)
혈청 크레아티닌	8.1292e-73	비흡연자(0.85) vs 흡연자(0.95) 유의미한 차이 있음 (흡연자 그룹이 높음)
고밀도지단백	1.1919e-54	비흡연자(59.35) vs 흡연자(53.91) 유의미한 차이 있음 (흡연자 그룹이 낮음)
공복 혈당	7.3560e-17	비흡연자(97.54) vs 흡연자(102.35) 유의미한 차이 있음 (흡연자 그룹이 높음)
헤모글로빈	0.0000e+00	비흡연자(14.16) vs 흡연자(15.44) 유의미한 차이 있음 (흡연자 그룹이 높음)

6. 이변량 분석

범주형 변수 vs 숫자형 변수 : 분산 분석 (ANOVA)

- 지표 그룹 : 20대/30대/40대/50대/60대/70대/70대이상

- ❖ F-statistic : 1에 가까우면 유의미하지 않음
- ❖ **F-statistic : 1보다 훨씬 크면 유의미한 차이가 있음**
- ❖ **t-value < 0.05 : 통계적으로 유의미한 차이 있음**
- ❖ t-value >= 0.05 : 통계적으로 유의미한 차이 없음

지표	F-statistic	p-value	결과
중성 지방	11.6180	7.1011e-13	유의미한 차이 있음
혈청 크레아티닌	6.1891	1.8440e-06	유의미한 차이 있음
고밀도지단백	4.1560	3.6636e-04	유의미한 차이 있음
공복 혈당	16.6703	5.9670e-19	유의미한 차이 있음
헤모글로빈	15.7340	8.0102e-18	유의미한 차이 있음

6. 이변량 분석

범주형 변수 vs 숫자형 변수 : 분산 분석 (ANOVA)

- 지표 그룹 : 저체중/ 정상/ 비만전단계 /1단계 비만 /2단계 비만 /3단계 비만
 - ❖ F-statistic : 1에 가까우면 유의미하지 않음
 - ❖ **F-statistic : 1보다 훨씬 크면 유의미한 차이가 있음**
 - ❖ **t-value < 0.05 : 통계적으로 유의미한 차이 있음**
 - ❖ t-value >= 0.05 : 통계적으로 유의미한 차이 없음

지표	F-statistic	t-value	결과
중성 지방	47.2661	6.9764e-47	유의미한 차이 있음
혈청 크레아티닌	4.6601	3.0791e-04	유의미한 차이 있음
고밀도지단백	63.0472	3.4677e-62	유의미한 차이 있음
공복 혈당	10.2240	1.0217e-09	유의미한 차이 있음
헤모글로빈	28.5382	2.9998e-28	유의미한 차이 있음

6. 이변량 분석

숫자형 변수 vs 범주형 변수 : 로지스틱 회귀모형


❖ **p-value < 0.05 : 통계적으로 유의미한 차이 있음**

❖ **p-value >= 0.05 : 통계적으로 유의미한 차이 없음**

지표	오즈비 (Odds Ratio)	t-value	결과
중성 지방	1.003944	0.000	- 통계적 유의성 큼
혈청 크레아티닌	1.958194	0.000	- 통계적 유의성 큼 - 흡연자가 비흡자에 비해 1.96배 높게 나타남
고밀도지단백	0.995807	0.055	- p-value가 기준치 경계이므로 참고 지표 활용 가능 - 음의 상관관계(0.99)를 보이므로 고밀도지단백(HDL) 수치는 흡연자일수록 낮게 나타남
공복 혈당	1.005072	0.000	- 통계적 유의성 큼
헤모글로빈	1.836901	0.000	- 통계적 유의성 큼 - 흡연자가 비흡자에 비해 1.83배 높게 나타남

7. 결론 및 인사이트

7.1 흡연의 강력한 생체 마커



헤모글로빈

혈액 내 산소 운반 능력을 나타내는
지표



혈청 크레아티닌

신장 기능을 평가하는 지표

7. 결론 및 인사이트

7.2 이상지질혈증 및 심혈관 질환 위험성 가시화



7. 결론 및 인사이트

7.3 구강 건강과 흡연의 상관성

- 구강 내 온도 상승
- 침 분비 감소
- 세균이 번식 증가



7. 결론 및 인사이드

7.4 나이대별 건강 지표 변화의 가속화

- 고령 흡연자
 - 흡연으로 인한 인슐린 저항성 악화가 더 심각해질 수 있음
 - 금연 치료와 함께 혈당 관리가 병행 필요



7. 결론 및 인사이드

7.5 분석 데이터의 한계점

- ❑ 대사 질환의 경우 호르몬의 영향
 - ❑ 성호르몬 : 대사 지표에 큰 영향을 미침
 - ❑ 성별 정보 파악 필요
 - ❑ 성별 교란변수의 개입 가능성 염두
- ❑ 성별이 지표에 미치는 영향
 - ❑ 헤모글로빈 수치 (남성 >여성) : 안드로겐 영향
 - ❑ 혈청 크레아티닌 수치 (남성 >여성) : 근육량에 비례

8. 프로젝트 활용방안

8.1. AI 예측 모델 활용

보험회사

- 보험가입시 흡연여부 판단
- 허위고지 방지
- 보험료 산정의 정확도 향상



병원

- 정밀진단 보조



금연치료 기관



- 전문적 치료제공
- 추적 검증

8. 프로젝트 활용방안

8.2. 개인 맞춤형 App 활용



- 검진 데이터 분석
- 개인화 솔루션 제공



End Of Document

