

GENE MUTATION • SELECTIVE ENSEMBLE

유전자 변이 기반 암종 분류 AI

육감으로 암종을 분류한다!
식스센스 6조

김은미
김지혜
박준영
정세준

DNA × TEXT × TREE × VOTE



목차

01

제공 데이터

DATA

02

데이터 분석

EDA

03

데이터 전처리

PREPROCESSING

04

피처 엔지니어링

FEATURES ENGINEERING

05

모델링

MODELING

06

후처리

Post-processing

07

검증 결과



VALIDATION

08


결론 및 제언

CONCLUSION

협업 과정 요약



Github(저장소) 구조



Notion 협업 구조

6,201개 학습 샘플로 26개 암종을 예측합니다

01 DATA

Train 6,201

Test 2,546

유전자 열 4,384개

02 TARGET

26개 SUBCLASS

최종 출력은 확률이 아닌

암종 hard label

03 METRIC

Macro F1

클래스별 F1을 동일 비중으로

OOF와 LB는 분리 해석

희소한 mutation string을 텍스트·구조 피처·전문가 예측으로 함께 해석합니다.

외부데이터 및 test-fit 사용 금지

모델 설계는 세 가지 데이터 난점에서 출발했습니다

0.805%


전체 유전자 셀 중 실제 변이가 관찰된 비율

20.7×

최대·최소 클래스의 표본 수 격차

1,005

동일 변이 프로파일 안에서 라벨이 섞인 행



행렬 희소성(Sparsity) → 다중 입력 표현

불균형 → class-balanced utility · 혼합 라벨 → disagreement 활용

소수 클래스까지 함께 보는 Macro F1이 기준입니다

상위 3개 암종


BRCA · KIPAN · GBMLGG

풍부한 표본 수를 보유하여 상대적으로 안정적인 학습이 가능합니다.

하위 3개 암종

DLBC · ACC · THYM

극소수의 표본만을 제공하며 대표적인 소수 클래스를 형성합니다.



불균형은 Pair Expert와 class-balanced selector 설계로 연결됩니다

변이 부담량은 구조 피처가 필요한 강한 신호입니다

전체 변이 부담량 (Mutation Burden) 분포

35.3개 vs **14개**

전체 평균 35.3개, 중앙값 14개의 긴 꼬리 분포

극단값 현황

2,393개 / 94명


최대값 2,393개, 변이가 없는 환자 94명 존재

암종별 극단적 편차

85.5개 vs **2개 / 3개**

SKCM 중앙값 85.5개 대비 THYM 2개, LAML 3개

주요 암종별 변이 부담량 중앙값 비교 (개)



burden · ratio · entropy 신호를 트리 기반 구조 피처로 보완합니다

같은 변이 프로필도 암종이 갈리며 단일 규칙은 부족합니다

중복 변이 프로필

451개 그룹 / 1,016명


동일한 변이 집합을 공유하는 환자군 규모

혼합 라벨 프로필

447개 그룹 / 1,005명

동일 프로필 내에 서로 다른 암종 라벨이 혼재

동일 변이 프로필의 암종 분기 구조



라벨 충돌을 Pairwise LR과 meta-model의 예측 불일치로 재해석합니다

EDA 심층 요약 및 모델링 연계

01. SPARSITY

행렬 희소성

- 4,384개 중 99% 이상이 WT/결측
- 극단적 데이터 희소성 확인

02. CONFLICT


라벨 충돌

- 동일 프로필 내 다른 암종 라벨 환자 1,016명 존재
- 결정 경계의 모호성 내포

03. LONG-TAIL

변이 부담량

- 평균 35.3개 vs 중앙값 14개로 우측 편향 분포
- 최대 2,393개 아웃라이어 존재



결측 신호를 보존하고 변이 유형을 정리

01

결측과 WT

결측값 → WT
missing_flags 별도 보존
missing_gene_count 생성

02

변이 유형 8종

DELINS · FS · DEL
INS · DUP · STOP
SUB · OTHER

03

중복 분류 방지

복합 표기를 먼저 판정
delins → del + ins
중복 분류 방지
p.V600E → V600E

04

표기 불일치

V600E → OTHER
V600>E → SUB
표기 정규화 필요

같은 유전자 변이 정보의 표기차이는 모델 신호를 분산시킬수 있다

한 개의 변이 셀에서 다층 토큰으로 확장



Word · Character TF-IDF를 결합합니다

01

Word TF-IDF

ngram 1-2
min_df 2
최대 250,000개

02

조합 신호

유전자 · 사건 토큰
인접 토큰의 결합
sublinear_tf 적용

03

Character TF-IDF

char_wb ngram 3-5
min_df 3
최대 180,000개

04

표기 변형

부분 문자열 포착
V600E 계열 패턴 공유
희귀 표기 일반화

05

희소 결합

`hstack(word, char × 0.5)`
float32 sparse matrix

Word를 주 신호로 사용하고
문자 피쳐는 보조로 반영

유전자 변이 이진 피처와 12개 구조 피처 제공

학습 데이터에서 상수인 피처는 제거

피처 그룹	차원	의미	주요 수요 모델
gene_mutated	유효 유전자 수	WT가 아니면 1	XGBoost / LightGBM
mutated_gene_count	1	변이 유전자 개수	부담량
event_count	1	전체 변이 이벤트 수	복잡도
multi_event_gene_count	1	다중 이벤트 유전자 수	multi-hit
missing_gene_count	1	원본 결측 유전자 수	측정 패턴
event_type_count	8	DELINS~OTHER 유형별 개수	변이 구성

Fold-safe로 Train과 Test를 분리

01

Train Fold fit

학습 Fold 행만 사용
feature_columns 확정
LabelEncoder 학습

02

어휘·마스크 학습

Word·Char 어휘 fit
유효 유전자 마스크 결정
Train 통계만 사용

03

Valid transform

고정된 어휘로 변환
통계 재계산 금지
동일 열 순서 유지

04

Test transform

학습된 객체만 적용
Test 분포를 fit에 미사용
새 토큰은 어휘 밖 처리

05


교차검증 안전성

각 Outer Fold마다
전처리 fit을 새로 수행

Text·Tree 행렬의 행 정렬과
schema를 동일하게 유지

변이 문자열 | 수치형 변수 분석

TF-IDF + LinearSVC



- 개요** 변이 문자열을 토큰 단위로 나누고, TF-IDF로 중요도 순 수치형으로 변환한 뒤, LinearSVC로 암종 사이의 경계를 학습.
- 기능** 가령 R132H(아르기닌→히스티딘) 같은 변이 표기의 전체 단어 패턴과, 문자열 일부가 공유하는 규칙을 정규화.
- 채택 이유** 유전자 변이 문자열은 차원이 높고 대부분 값이 0인 복합적 변수. LinearSVC는 이런 자료를 measurable하게 하고(McElfresh, 2023), 희소벡터를 분류하는 선형모델로 활용할 수 있음(권철민, 2022).

R132H · P403fs · L21* → TF-IDF 벡터(R·132·H) → LinearSVC → 암종 예측

XGBoost

표본 ID	실제 암종	변이 변이 수	변이 유전자 수	Missense	Truncating	반복 위치 변이	일종도(94%)
TRAIN_6190	PCPG	3	3	1	0	0	0.333
TRAIN_0031	GBMLGG	9	9	8	0	3	0.111
TRAIN_6194	KIPAN	20	20	12	1	0	0.050
TRAIN_4683	SKCM	70	69	44	4	0	0.015

- 개요** 여러 결정트리를 순차로 학습하면서 앞선 트리의 오분류를 다음 트리가 보완하는 경사 하강법을 활용한 모델.
- 기능** 변이 개수, 변이 유형, hotspot, 유전자 집중도처럼 정형 데이터로 정리한 특성 사이의 비선형 관계를 학습.
- 채택 이유** 암종별 패턴은 수치 합산이 아니라 여러 특성의 조합으로 유기적으로 나타남. XGBoost는 이러한 조건 조합을 트리 분기로 표현하기 유리함(웨이드, C., 2022).

변이 수 · 유형 · hotspot.etc → 트리 반복 학습 → 암종별 확률

LinearSVC는 문자열 규칙을, XGBoost는 숫자 특성의 조합을 담당해 서로 다른 정보를 보완하여 모델링.

상호보완적 모델 결합 및 앙상블



LightGBM

개요 오차를 순차적으로 줄이는 트리 모델

주요 기능 많은 희소 특성을 효율적으로 묶고 중요한 표본에 집중

채택 이유 XGBoost와 유사한 강점을 가지면서 학습 속도와 메모리 효율이 좋음

ExtraTrees

개요 분할 변수와 임계값 선별 기준에 무작위성을 높인 트리 앙상블

주요 기능 여러 무작위 트리의 다수결로 비선형 패턴 분류(<->Random forest 최적값)

채택 이유 부스팅 모델과 다른 방식으로 판단해 앙상블의 다양성을 높임

Logistic Regression

개요 선택한 두 암종만 구분하는 이진 분류

주요 기능 KIRC-KIRP처럼 반복 혼동된 쌍의 경계를 다시 학습

채택 이유 26개 전체 결과는 통제된 채로, 문제가 된 두 암종만 제한적으로 보완

LightGBM · ExtraTrees · Logistic Regression을 결합하여 비선형 변이 패턴을 보완하고, 혼동되는 암종을 더욱 정밀하게 구분.

스태킹 학습& 교차 검증

STEP 1 · STACKING

여러 모델의 결과를 다시 학습

1 개별 모델 학습

변이 문자열·수치·정형데이터
모델을 각각 학습시킨다!



2 OOF 결과 생성

각 환자를 학습에 쓰지 않은 모델
결과 저장(환자A 제외 학습, 환자 A 예측)



결합 모델

Logistic Regression: 모델별 각 암종에 부여한 예측 점수를 입력받아,
모델별 중요도를 학습하고 최종 예측으로 **결합**

LightGBM: 모델들의 예측 점수 사이에 존재하는 비선형 관계와 조건별 조합을
학습하여 최종 암종을 판단

STEP 2 · VOTESELECT

근거가 충분한 패턴만 최종 보정

① 예측 결과 결합

각 모델이 고른 암종을 하나의 정답 인덱스 조합으로 형성

② 반복 여부 확인

같은 답 조합이 OOF에서 3회 이상 나온 경우만 최종 선택

③ 암종별 점수 계산

표본이 적은 암종도 불리하지 않게 균등하여 가중치 조절


④ 최종 판단

암종의 결정 계수가 1.0 이상 높을 때만 예측을 변경

마진(결정경계와의 거리)이 클수록 분류 근거가 강하다는 SVM 원리(Cortes & Vapnik, 1995) 및 선행연구에 따라, OOF 교차검증으로 정한 결정함수 점수 차이가 1.0을 넘을 때만 예측을 보정

조건부 보정 효과 & 일반화 적용 한계

5-fold OOF Macro F1 (%)



성능개선 +0.019777

Public Macro F1 0.466060

결과 해석

개선 효과 OOF Macro F1이 0.620409에서 0.640186으로 상승.

적용 범위 OOF에서 반복적으로 개선된 59개의 모델 예측 조합을 조건부 전환 규칙으로 사용(475건).

안전장치 패턴과 정확히 일치할 때만 결과를 변경(임의판단 배제).

일반화 한계 OOF 상승 폭만큼 Public 점수가 오르는 것이 아니라, 과적합 가능성 한계.

최종 판단

문자열·표 데이터·혼동쌍 모델이 서로 다른 오류를 보완하고, 교차검증에서 반복 확인된 경우에만 최종 답을 바꾸도록 적용 범위를 제한

Stratified 5-fold OOF Macro F1

STRATIFIED

클래스 비율 유지

26개 암종의 불균형을 반영해
Fold별 클래스 분포를 유사하게 유지

OOF

누수 없는 예측

각 표본은 자신을 학습에 쓰지 않은
모델·규칙으로 한 번씩 평가


MACRO F1

소수 암종 동등 반영

암종별 F1을 동일 비중으로 평균해
다수 클래스 편향을 완화

클래스 불균형을 고려하면서 미관측 데이터에 가까운 내부 일반화 성능을 평가

단계별 핵심 성과 요약 (전처리 -> 모델링 -> 후처리)



OOF MACRO F1 SCORE

01 BASE OOF

0.62041

Logistic-Regression

02 FINAL OOF

0.64019

+0.019777

03 RECORDED PUBLIC


0.46606

리더보드 기록값

v2는 OOF 0.648760이지만 리더보드 기록 0.453558 → v1 유지

전체 실험에서 가장 큰 단일 상승은 VoteSelect 단계였습니다

실험	핵심 변경
004_1	TF-IDF + Tree 기본 앙상블
004_2	Soft 충돌 보정
004_3	Strict pair 재판정
004_4	비대칭 보정
004_5	C · weight · offset
004_6	EM v14 전문가
004_7	EM16 · 24 pair expert
004_8	VoteSelect v1
004_9	VoteSelect v2 완화



004_8은 004_7 대비 OOF **+0.111616** · Public 최고 **0.466060**을 기록

Voter의 불일치를 Select

ALL AGREE

84.59%

n = 1,960
Base accuracy

DISAGREE

44.94%

n = 4,241
Base accuracy

INTERPRET

위험 신호

약한 voter도 다양성 가치 가능

성능은 분명히 향상됐지만, OOF-Public 전이 격차는 남았습니다

01 · MODEL BUILD

4,384 → 26,000+

원본 유전자 피처를 정교한
파생 피처로 확장해 5개 모델 학습
5개 예측을 메타 피처로 최종 보정

02 · REALITY CHECK

0.640 vs 0.466

OOF Public
격차 0.174 · 17.4%p
미관측 패턴으로의 전이 한계

03 · POSITION & NEXT

보조 스크리닝 → 확률 보정

단독 진단이 아닌 2차 보조 도구
Soft Calibration으로
일반화 격차 축소

결론 | 베이스라인 개선과 선택적 보정 효과는 확인 — 다음 목표는 미관측 패턴 일반화