

흉부 X-ray 이미지 분류 AI 해커톤

Baseline 개선 실험, 앙상블 분석, Grad-CAM 설명가능성 검토

1. 문제 정의

1.1 Baseline 성능

지표	Baseline 성능
Accuracy	94.75%
AUC	0.9937
F1-score	0.9268
Recall	0.9025

1.2 주요 문제점

① 검증 데이터가 없음

현재 노트북은 train.csv 전체로 학습하고 바로 test를 예측합니다. Validation set이 없기 때문에 모델이 실제로 잘 학습했는지, 과적합인지, 폐렴을 얼마나 놓치는지 알 수 없습니다.

② 모델 구조가 너무 단순함

현재 모델은 Conv layer 2개짜리 SimpleCNN입니다. 흉부 X-ray처럼 병변이 작고 흐릿한 의료영상에서는 폐 음영, 국소 병변, 전역 패턴을 충분히 학습하기 어렵습니다.

③ 전처리와 학습 전략이 의료영상에 맞지 않음

이미지를 단순히 grayscale 후 128x128로 줄입니다. 폐렴 병변 정보가 손실될 수 있고, 클래스 불균형이나 False Negative 감소 전략도 없습니다.

2. 개선 전략

개선 전략	내용 및 기대 효과
검증데이터 생성	train/validation을 8:2로 나누고 학습한 모델에 대한 성능을 검증합니다.
이미지 사이즈 증가	모델에 입력되는 정보의 해상도가 높아져 이미지 내의 디테일한 픽셀 정보가 보존됩니다.
Epoch 증가	모델이 전체 훈련 데이터를 더 여러 번 반복해서 보며 가중치를 조정하여 손실을 최소화하고 성능을 향상 시킵니다.
이미지 픽셀값 정규화	모든 입력 특성의 스케일이 비슷해지면 경사 하강법이 최적해를 찾아가는 경로가 부드러워져 더 빠르고 안정적으로 수렴합니다.
Conv layer 수 증가	네트워크가 깊어질수록 더 복잡하고 추상적인 특징을 추출할 수 있습니다.
BatchNorm2d 추가	가중치 초기화에 덜 민감해지고, 더 큰 학습률을 사용할 수 있어 수렴 속도가 빨라지며 기울기 소실/폭발 문제를 완화합니다.
Dropout2d 추가	특정 시각적 패턴이나 일부 채널에 과도하게 의존하는 것을 막아 과적합 방지 효과를 제공합니다.

3. 실험 설계

실험	모델 구성 / 변경 사항	IMG_SIZE	EPOCHS	BATCH	Loss	Optimizer	Early Stopping
baseline	SimpleCNN (Conv layer=2)	128	2	32	CrossEntropyLoss	Adam	-
TICKET-001	base 모델에 IMG_SIZE·EPOCHS·Conv layer 증가 (Conv layer=3), BatchNorm2d, Dropout2d 추가	224	20	32	-	Adam	-
TICKET-002	주모델 변경: DenseNet121	224	40	16	CrossEntropyLoss	AdamW	patience=5
TICKET-003	DenseNet121 + EfficientNet-B0 앙상블	224	40	16	-	AdamW	patience=5
TICKET-004	DenseNet121 + EfficientNet-B0 + ConvNeXt-Tiny 앙상블	224	40	16	-	AdamW	patience=5
TICKET-005	DenseNet121 + EfficientNet-B0 + ConvNeXt-Tiny + Swin Transformer 앙상블	224	25	8	-	AdamW	patience=5
TICKET-006	DenseNet121 + EfficientNet-B0 + ConvNeXt-Tiny + Swin Transformer + XGBoost 앙상블	224	25	8	-	AdamW	patience=5

※ '-'는 원문에 별도 기재가 없는 항목입니다.

4. 결과 비교

지표	baseline	TICKET-001	TICKET-002	TICKET-003	TICKET-004	TICKET-005	TICKET-006
Accuracy	0.9475	0.9459	0.9875	0.9837	0.9875	0.9923	0.9923
AUC	0.9937	0.9862	0.9965	0.9990	0.9995	0.9973	0.9998
F1-score	0.9268	0.9311	0.9838	0.9788	0.9837	0.9912	0.9901
Recall	0.9025	0.9434	0.9867	0.9829	0.9855	0.9882	0.9897

※ 빨간 굵은 글씨는 지표별 최고값입니다.




그림 1. 실험별 성능 지표 비교 그래프

결과 해석

TICKET-002에서 DenseNet121로 주모델을 변경하면서 모든 핵심 지표가 크게 개선되었습니다. TICKET-005는 Accuracy와 F1-score 측면에서 가장 우수했으며, TICKET-006은 AUC와 Recall이 높았지만 XGBoost 추가 과정에서 데이터 누수 및 확률 calibration 문제가 발생할 수 있음을 확인했습니다.

5. 실패 사례 분석

5.1 실패 케이스: TICKET-006

구분	내용
모델 구성	DenseNet121 + EfficientNet-B0 + ConvNeXt-Tiny + Swin Transformer + XGBoost 앙상블
학습 방식	기존 딥러닝 모델은 다시 학습하지 않고, 각 모델의 class probability를 XGBoost 입력 feature로 사용했습니다.
입력 feature	이진 분류에서는 각 모델의 normal/pneumonia 확률을 모두 넣고, 기존 weighted ensemble 확률도 feature로 추가했습니다.

5.2 원인 분석

- ① **Data Leakage 및 과적합**

4개의 딥러닝 모델을 학습시켰던 Train Data를 그대로 다시 모델에 통과시켜 확률값을 뽑아내고, 이를 XGBoost의 입력값으로 사용했기 때문에 심각한 Data Leakage가 발생했습니다.
- ② **다중공선성 및 피쳐 중복**

Normal 확률과 Pneumonia 확률은 완벽한 음의 상관관계를 가지므로 동일한 정보가 중복 입력됩니다. 트리 기반 모델에서는 고도로 중복된 피쳐가 많아지면 분기점 선택에 노이즈가 생길 수 있습니다.
- ③ **딥러닝 모델 확률의 Calibration 문제**

DenseNet, EfficientNet 등 현대의 복잡한 딥러닝 모델은 성능이 높더라도 예측 확률이 과신되는 경우가 있습니다. 여러 모델이 서로 다른 스케일로 과신된 확률을 출력하면 XGBoost가 어떤 모델의 확률을 신뢰해야 할지 판단하기 어려워집니다.


6. Explainability: Grad-CAM 분석

분석 기준

Grad-CAM은 모델이 예측할 때 어느 영역을 중요하게 보았는지 시각화합니다. 의료영상에서는 단순 성능뿐 아니라 실제 병변 또는 폐 영역에 attention이 집중되는지 확인하는 것이 중요합니다.

실험	모델	핵심 문제점 요약
TICKET-002	DenseNet121	폐 병변이 아닌 주변 구조를 보며, 폐렴 위치에 대한 국소 집중도 부족
TICKET-003	DenseNet121 + EfficientNet-B0	폐 외곽/영상 경계를 보는 경우가 있고, 심장/종격동/횡격막 주변에 과도하게 반응
TICKET-004	+ ConvNeXt-Tiny	정상 이미지를 폐렴으로 잘못 보는 false positive 가능성
TICKET-005	4개 딥러닝 모델 앙상블	attention이 너무 넓고 흐릿하여 흉부 중앙 전체를 넓게 보는 경향

6.1 TICKET-002 - DenseNet121



TICKET-002 Grad-CAM 결과 이미지


분석 결과

- 이 모델은 폐렴 병변 자체만 안정적으로 보는 모델은 아직 아닙니다.
- 일부 이미지는 폐 영역을 보고 있지만, 여러 샘플에서 폐 바깥, 횡격막, 심장 음영, 영상 가장자리, 자세/회전 정보에 반응하는 모습이 보입니다.

핵심 문제점

모델이 폐 병변이 아니라 주변 구조를 보고 있으며, 폐렴 위치에 대한 국소 집중도가 부족합니다.

6.2 TICKET-003 - DenseNet121 + EfficientNet-B0



TICKET-003 Grad-CAM 결과 이미지


분석 결과

- 모델이 폐 영역을 어느 정도 참고하고는 있지만, 폐렴 병변 중심으로 안정적으로 판단한다고 보기는 어렵습니다.
- 특히 일부 샘플에서 heatmap이 폐 바깥쪽, 영상 경계, 우측 하부, 심장/횡격막 주변에 강하게 나타납니다.

핵심 문제점

폐렴 병변보다 폐 외곽/영상 경계를 보는 경우가 있으며, 심장/종격동/횡격막 주변에 과도하게 반응합니다.

6.3 TICKET-004 - DenseNet121 + EfficientNet-B0 + ConvNeXt-Tiny




TICKET-004 Grad-CAM / Grad-CAM++ 결과 이미지

분석 결과

- Grad-CAM / Grad-CAM++ 결과를 보면, 이 모델은 폐렴 판단을 할 때 폐 내부 병변만 보는 것이 아니라 폐 외곽, 영상 경계, 횡격막 주변에 상당히 의존하고 있습니다.
- 특히 border 값이 높은 샘플이 많아 모델이 의학적 병변보다 이미지 가장자리 또는 촬영 패턴을 학습했을 가능성이 있습니다.

핵심 문제점 — 정상 이미지를 폐렴으로 잘못 보는 false positive 가능성이 있습니다.

6.4 TICKET-005 - 4개 딥러닝 모델 앙상블



TICKET-005 Grad-CAM 결과 이미지

분석 결과

- 모델이 흉부 X-ray 전체를 무작위로 보는 것은 아니고 폐 영역 중심부를 어느 정도 참고하고 있습니다.
- 그러나 병변 위치를 정밀하게 잡는다고보다는 심장 음영, 종격동, 폐문부, 횡격막 주변에 넓게 반응하는 경향이 강합니다.

핵심 문제점

attention이 너무 넓고 흐릿합니다. 병변이 있는 특정 위치를 정확히 짚는다고보다 흉부 중앙 전체를 넓게 보는 경향이 있습니다.

7. 최종 인사이트

7.1 성능 개선의 핵심 요인

No.	핵심 요인
1	분석하는 데이터에 적합한 모델 선택
2	서로 성능을 보완할 수 있는 모델로 앙상블 구성

7.2 실무 적용 가능성

관점	내용
서비스 개요	본 서비스는 흉부 X-ray 영상을 기반으로 폐렴 의심 여부를 자동 분석하고, Grad-CAM을 통해 모델이 판단에 활용한 영상 영역을 시각화하는 AI 판독 보조 서비스로 실무 적용 가능성이 높습니다.
적용 현장	병원 영상의학과, 응급실, 건강검진센터, 보건소, 원격의료 지원 환경 등에서 X-ray 판독 업무의 1차 선별, 우선 순위 분류, 의심 환자 조기 발견에 활용할 수 있습니다.
예측 안정성	DenseNet121, ConvNeXT, EfficientNet, Swin Transformer를 함께 사용하는 앙상블 방식은 단일 모델보다 예측 안정성을 높일 수 있습니다.
설명가능성	Grad-CAM을 적용하면 단순히 정상/폐렴 결과만 제공하는 것이 아니라, 모델이 어느 폐 영역을 근거로 판단했는지 시각적으로 제시할 수 있습니다.
활용 형태	따라서 의료진이 AI 결과를 무조건 수용하는 방식이 아니라, AI 판단 근거를 참고하여 최종 판독을 보조하는 형태로 활용하기에 적합합니다.

8. 실험 과정 회고

8.1 가장 효과 있었던 전략

TICKET-002 주모델 변경: DenseNet121

DenseNet121은 ImageNet 등으로 사전 학습된 가중치를 활용해 적은 데이터와 짧은 학습 시간으로도 이미지 분류에서 높은 정확도를 달성할 수 있는 딥러닝 모델입니다. 의료 영상(X-ray 등)과 같이 특화된 이미지 분석에서도 강점을 보였습니다.

8.2 실패했지만 의미 있었던 시도

TICKET-006 DenseNet121 + EfficientNet-B0 + ConvNeXt-Tiny + Swin Transformer + XGBoost 앙상블

- 데이터 누수와 피쳐 중복이 모델 성능에 미치는 영향을 확인할 수 있었습니다.
- DenseNet, EfficientNet 등 현대의 복잡한 딥러닝 모델 사용 시 각기 다른 스케일로 과신된 확률을 출력하면, XGBoost와 앙상블했을 때 오히려 성능이 떨어질 수 있음을 확인했습니다.